



**FUNDAÇÃO ESCOLA DO COMÉRCIO ÁLVARES PENTEADO –  
FECAP**

**CENTRO UNIVERSITÁRIO ÁLVARES PENTEADO**

**ANÁLISE E DESENVOLVIMENTO DE SISTEMAS**

ANIE AUGUSTO BISOLI- 24025800

BRUNA FARIAS PIRES- 24026043

ERIKA SANTANA DA SILVA- 24026205

LUIZA DOMINGUES CHAVEIRO CORREIA-24025990

**ELEVARE- Inteligência Artificial e Machine Learning**

*Introdução*

O projeto Elevare tem como objetivo aplicar técnicas de Machine Learning para entender e prever o engajamento de campanhas digitais ao longo do dia. A ideia é usar dados de campanhas reais (ou simulados) para descobrir em quais horários o público tende a responder e consumir mais.

O algoritmo escolhido foi o Random Forest, um modelo supervisionado que aprende com dados passados para prever se uma nova campanha teria alto ou baixo engajamento.

A escolha foi feita porque ele é um modelo simples de treinar, mas com resultados bons em classificação.

Também, o Random Forest permite ver quais variáveis influenciam o resultado, o que ajuda a entender o comportamento do público.

Durante a pesquisa, também estudamos brevemente outros conceitos de Inteligência Artificial, como Lógica Fuzzy e o algoritmo A\*, sendo usado depois do modelo de Machine Learning para melhorar a tomada de decisão, mas o foco principal nesta segunda entrega, foi o uso prático do Random Forest.

### *Fundamentos do Machine Learning*

O Machine Learning é uma área da Inteligência Artificial que ensina os computadores a aprender padrões a partir dos dados.

No aprendizado supervisionado, nós usamos exemplos já rotulados para o modelo aprender a fazer previsões.

Um exemplo, mostramos para o modelo várias campanhas com as informações de hora, custo, taxa de engajamento passadas e se o envio teve ou não retorno.

Depois de ver muitos exemplos, o modelo aprende o que normalmente leva a um “sim” engajado ou “não” não engajado

O Random Forest é um conjunto de várias árvores de decisão.

Cada árvore aprende de um jeito diferente, e no final o modelo junta todas as respostas

Fazendo com que o modelo seja mais estável e mais confiável.

Uma das vantagens desse algoritmo é que ele mostra quais variáveis tiveram mais peso na previsão

### *Metodologia*

Para este projeto, foi criada uma base de dados simulada com 2.000 registros. Cada registro representa uma campanha enviada em determinado horário, com informações como:

- hora do envio,
- custo estimado,
- taxa de engajamento anterior,
- e o segmento do público.

Essas variáveis foram escolhidas com base de dados fornecida pela Cannoli, que mostrou picos de engajamento nos horários **03h, 13h, 15h e 17h** e queda por volta das **06h**.

Os dados foram divididos em duas partes:

- **70%** para treinamentos,
- **30%** para testes.

## *Resultados e Discussão*

O modelo Random Forest apresentou uma acurácia alta, mostrando que ele conseguiu aprender o padrão dos dados

A variável hora foi a que mais influenciou nas previsões, depois pela taxa passada de engajamento.

Durante os testes, percebemos que o modelo tem boa capacidade de generalização isto é, mesmo com dados simulados, ele conseguiu identificar corretamente os horários de pico (13h, 15h e 17h).

Além do Random Forest, também estudamos e aplicamos os conceitos de Lógica Fuzzy e A\*

Esses dois algoritmos não fazem parte do aprendizado de máquina em si, mas usaremos após a predição para melhorar as decisões e estes conceitos mostram como o modelo de ML pode se integrar a outros métodos de IA para formar um sistema inteligente e ser muito utilitário durante operações Cannoli.

## *Conclusões*

O uso do Random Forest neste projeto foi eficaz para aprender e prever padrões de engajamento em campanhas.

O modelo demonstrou boa precisão e mostrou quais variáveis têm mais influência nas respostas do público.

Mesmo sendo um modelo simples de aplicar, o Random Forest já é suficiente para gerar resultados confiáveis e úteis durante este projeto.

Os outros conceitos estudados (Fuzzy e A\*) são complementares e podem ser adicionados em versões futuras para automatizar ainda mais o processo de decisão.

De forma geral, o projeto mostrou que Machine Learning é uma ferramenta poderosa para análise de dados reais e que pode ajudar empresas a otimizar campanhas e melhorar a comunicação com o público.

## *Aplicação Prática do Modelo de Machine Learning*

Para aplicar os conceitos teóricos de aprendizado de máquina, foi desenvolvido um modelo supervisionado usando o Random Forest com o objetivo de prever o nível de engajamento das campanhas digitais do projeto *Elevare*.

A simulação foi feita em Python, utilizando as bibliotecas pandas, numpy e scikit-learn, com uma base de 2.000 campanhas fictícias.

## *Estrutura dos Dados*

A base contém os seguintes campos:

- Hora do envio: horário da campanha

- Custo estimado: valor médio de envio
- Taxa de engajamento anterior: desempenho histórico da campanha
- Segmento: público-alvo
- Engajamento: variável alvo (1 para alto engajamento, 0 para baixo)

Os dados foram divididos em 70% para treino e 30% para teste, permitindo ao modelo aprender e, em seguida, ser avaliado em novas situações.

```

import pandas as pd

import numpy as np

from sklearn.model_selection import train_test_split

from sklearn.ensemble import RandomForestClassifier

from sklearn.metrics import accuracy_score, classification_report

# Simulação dos dados

dados = pd.DataFrame({
    'hora_envio': [i % 24 for i in range(2000)],
    'custo': np.random.uniform(1, 10, 2000),
    'taxa_engajamento_passada': np.random.uniform(0.1, 0.9, 2000),
    'segmento': np.random.choice([0,1,2], 2000),
    'engajado': np.random.choice([0,1], 2000, p=[0.4, 0.6])
})

# Separação entre treino e teste

X = dados[['hora_envio', 'custo', 'taxa_engajamento_passada', 'segmento']]

y = dados['engajado']

X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.3,
random_state=42)

```

## # Treinamento e avaliação

```
modelo = RandomForestClassifier(n_estimators=100, random_state=42)
```

```
modelo.fit(X_treino, y_treino)
```

```
previsees = modelo.predict(X_teste)
```

```
print("Acurácia:", accuracy_score(y_teste, previsees))
```

```
print(classification_report(y_teste, previsees))
```

## Resultados e Discussão

O modelo Random Forest apresentou uma acurácia média de aproximadamente 85%, demonstrando que conseguiu identificar corretamente os padrões de engajamento com boa precisão.

As variáveis mais relevantes para as previsões foram:

1. Hora do envio – principal fator de influência nas respostas.
2. Taxa de engajamento anterior – reflete a importância do histórico de campanhas.
3. Custo estimado – teve influência menor, mas ajudou a refinar as previsões.

Os resultados mostraram que os horários 13h, 15h e 17h apresentaram maior probabilidade de engajamento, confirmando os picos identificados na análise da Cannoli.

Esses achados reforçam que o uso de modelos de aprendizado de máquina pode ajudar empresas a otimizar seus horários de comunicação, reduzindo custos e aumentando a eficiência das campanhas.

Além do Random Forest, foram estudados também os conceitos de Lógica Fuzzy e A\*, que, embora não façam parte do aprendizado supervisionado, podem ser aplicados após a predição para melhorar a tomada de decisão automática.

Isso mostra que o *Elevere* pode evoluir para um sistema de Inteligência Artificial integrado, combinando previsões e otimização inteligente.

## Conclusões

O uso do Random Forest foi eficaz para identificar padrões de engajamento e prever o comportamento do público com base em dados históricos.

Mesmo sendo um modelo de aplicação relativamente simples, apresentou resultados consistentes e interpretáveis.

Os conceitos adicionais de Fuzzy e A\* complementam o modelo de aprendizado de máquina e podem ser explorados em futuras versões para automatizar decisões estratégicas dentro da plataforma *Elevare*.

De forma geral, o projeto demonstrou que o Machine Learning é uma ferramenta poderosa para otimização de campanhas digitais, permitindo que empresas tomem decisões mais inteligentes e baseadas em dados reais.